

**SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU**  
**FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I**  
**INFORMACIJSKIH TEHNOLOGIJA OSIJEK**

Diplomski sveučilišni studij Računarstvo

**Objašnjiva klasifikacija hiperspektralne slike**

Obrada slike i računalni vid

Valentin Veselčić

Osijek, 2025.

# SADRŽAJ

1. UVOD.....	2
2. TEORIJSKA POZADINA .....	3
2.1. Hiperspektralne slike (HSI) .....	3
2.2. CNN-ovi za klasifikaciju HSI.....	4
2.3. XAI metode pri klasifikaciji HSI.....	7
3. EKSPERIMENTALNA ANALIZA.....	9
3.1. REZULTATI.....	10
4. ZAKLJUČAK .....	17
LITERATURA .....	18

## 1. UVOD

Hiperspektralna slika (engl. *hyperspectral image*, *HSI*) sastoji se od piksela opisanih velikim brojem kanala. Svaki kanal odgovara određenoj valnoj dužini elektromagnetnog spektra. Ove slike sadrže znatno više informacija od klasičnih slika koje uzimaju u obzir samo raspon valnih duljine vidljive ljudskom oku, što znači da se svakim pikselom bolje može identificirati što on predstavlja. Hiperspektralne slike imaju veliki spektar primjena, jedna od kojih je mapiranje zemljine površine gdje veliki broj prikupljenih spektara omogućuje bolju identifikaciju objekata na slici kao i samog tipa terena.

Neuronske mreže, posebice konvolucijske neuronske mreže (CNN) su se pokazale kao dobar alat u identificiranju uzoraka i veza u informacijama koje hiperspektralne slike sadrže. Neuronske mreže automatski određuju iz velikog broja informacija koje prime one koje su bitne za pojedinu klasu tijekom postupka klasifikacije, uzimajući u obzir pojedine kanale kao i njihove međusobne utjecaje.

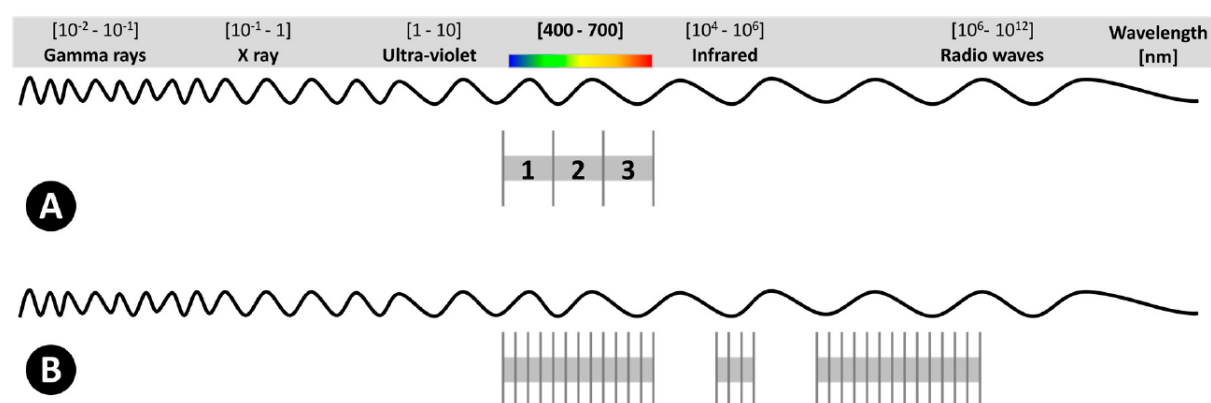
Ipak za kvalitetno prikupljanje i predobradu podataka, kao i za razumijevanje što neuronska mreža smatra bitnim potrebno je znati više o tome kako neuronske mreže uče nego što njihov način rada crne kutije (engl. *black-box*) dozvoljava. Metode objašnjive umjetne inteligencije (engl. *explainable artificial intelligence*, *XAI*) daju načine objašnjavanja kako neuronske mreže rade i omogućavaju jednostavniju interpretaciju istih. Korištenjem tih alata možemo identificirati utjecaje koji pojedini kanali imaju na klasifikaciju.

## 2. TEORIJSKA POZADINA

Kako bi se postigla što učinkovitija analiza hiperspektralnih podataka, ključno je razumjeti teorijske osnove i metode korištene u ovom radu. U sljedećem poglavlju opisani su: (1) osnovni principi hiperspektralnih slika, (2) arhitekture CNN-ova optimizirane za HSI klasifikaciju, te (3) XAI metode korištene za interpretaciju odluka modela. Ova teorijska podloga bit će temelj za eksperimentalnu analizu opisanu u kasnijim poglavljima.

### 2.1. Hiperspektralne slike (HSI)

Glavna razlika između tipičnih RGB slika prisutnih u svakodnevici i hiperspektralnih slika je broj kanala i raspon elektromagnetnog zračenja koje one bilježe. Za RGB slike to su 3 kanala koji sadržavaju čovjekovom oku vidljivi raspon valnih duljina od 400nm do 700nm, dok za hiperspektralne slike to može biti stotine ili pak tisuće kanala koje sadržavaju uže raspon valnih duljina (5-20nm) [1].



**Slika 2.1.** Predstava kanala i valnih duljina (A) RGB, i (B) hiperspektralnih slika u elektromagnetnom spektru

Hiperspektralne slike kao takve imaju veliki potencijal u prikupljanju informacija o snimanim objektima bez direktne interakcije s njima. Primjene hiperspektralnih slika su brojne u velikom broju područja, neke od njih su u procjeni kvalitete i sigurnosti hrane [2] koristeći HSI za inspekciju spoljašnjosti i unutrašnjosti hranidbenih proizvoda, poljoprivredi [3], gdje se koriste za analizu i optimizaciju uzgoja hrane.

Ipak rad s HSI nije bez izazova, s obzirom na to da se sastoje od velikog broja dimenzija problemi se javljaju u njihovoj obradi u stvarnom vremenu, gdje s većim brojem sadržanih podataka računalni zahtjevi se povećavaju. Također ovisno o atmosferskim uvjetima i jačini

zračenja dolazi do pojave šuma i artefakata u podacima, što dovodi do toga da stvarni spektralni potpis fizičke materije nije jednak onom koji je detektiran senzorom.


Spektralni potpis predstavlja spektar elektromagnetnog zračenja koji materijal reflektira i po njemu se može identificirati. Primjerice cirus oblaci koji se nalaze na velikim visinama mogu se identificirati spektrima u rasponu 1360-1380nm, voda 450-510nm, led 3000-3200nm, drveće od 700nm pa nadalje [4].

## 2.2. CNN-ovi za klasifikaciju HSI

Konvolucijske neuronske mreže (engl. *Convolutional Neural Networks, CNNs*) su specijalizirana vrsta dubokih neuronskih mreža dizajnirana za obradu strukturnih podataka s grid-topologijom, posebice slika i višedimenzionalnih signala. Temeljni koncept CNN-a je korištenje lokalnih povezivanja i prostorne hijerarhije kroz slojeve koji progresivno izdvajaju značajke od niskog do visokog nivoa apstrakcije.

Ključne komponente CNN-a uključuju: konvolucijski slojevi koji koriste kernele koji detektiraju lokalne obrasce (rubovi, teksture, oblici), pooling slojeve, najčešće su to slojevi sažimanja (engl. *max pooling*), dropout slojeve i na kraju potpuno povezane slojeve za konačnu klasifikaciju ulaznih podataka.


Prvi sloj CNN-a je konvolucijski sloj koji se sastoji od kernela koji primjenjuje na ulazne podatke. Kerneli su matrice sačinjene od težina koje predstavljaju trenirane parametre modela.



Slika 2.2. Primjer konvolucije između ulazne slike i kernela

Nakon što je obavljena konvolucija između kernela i svih ulaznih podataka značajke se dalje šalju sljedećem sloju.


Primarna svrha pooling sloja je smanjivanje prostorne složenosti izlaza iz prethodnog konvolucijskog sloja, zadržavajući pri tome najvažnije informacije. Ovaj postupak ne uključuje učenje parametara, već primjenjuje unaprijed definiranu operaciju nad lokalnim područjima ulaznih podataka. Najčešće korištena tehnika je max pooling, gdje se iz svakog lokalnog područja (npr. prozora  $2 \times 2$ ) odabire maksimalna vrijednost, čime se ističu najizraženija obilježja, povećava robusnost modela na male prostorne pomake i smanjuje overfitting modela. Osim max poolinga, postoje i alternative poput average poolinga (uzima prosječnu vrijednost) i L2-norm poolinga (koristi kvadratni korijen zbroja kvadrata).



**Slika 2.3.** *Primjer max pooling sloja*

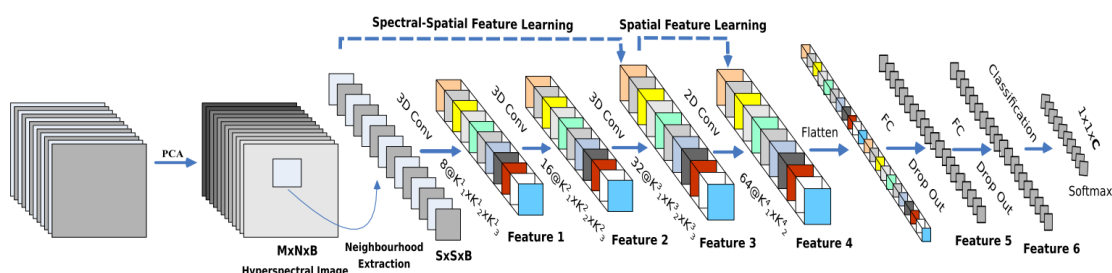
Dropout sloj je tehnika regularizacije koja slučajno odabire i postavlja na nulu dio neurona tijekom treniranja, što sprječava overfitting tjerajući mrežu da se ne oslanja previše na pojedinačne neurone.

Potpuno povezani sloj ima svaki neuron povezan sa svakim neuronom prethodnog sloja. Primajući značajke iz prethodnih slojeva, ovaj sloj ih mapira u konačan izlaz odgovarajuće dimenzije (npr. broj klasa u problemu klasifikacije). Koristi aktivacijsku funkciju poput softmax (za višeklasnu klasifikaciju) ili sigmoid (za binarnu klasifikaciju/regresiju) kako bi generirao konačne vjerojatnosti ili predviđene vrijednosti. U kombinaciji s funkcijom gubitka (npr. cross-entropy), posljednji sloj optimizira parametre kroz backpropagation, omogućujući modelu donošenje preciznih predviđanja.



**Slika 2.4.** *Potpuno povezani sloj*

Radi svoje hijerarhijske strukture CNN-ovi pokazali su se kao dobar alat u klasifikaciji HSI, automatski izdvajaju i kombiniraju bitne informacije iz ulaznih podataka. Ipak klasične arhitekture konvolucijskih mreža poput LeNet-5 nisu direktno primjenjive za hiperspektralne slike. S obzirom na to da se svaki piksel hiperspektralnih slika može promatrati kao 2D slika, osnovni 2D-CNN pristup tretira hiperspektralne slike kao niz 2D slika, što omogućuje efikasnu analizu prostornih obilježja, ali uz određeni gubitak spektralnog konteksta. S druge strane, 3D-CNN arhitekture izravno obrađuju prostorno-spektralne kocke podataka, čime se bolje koristi dostupnost spektralnih informacija, uz veće računske zahtjeve [5].



**Slika 2.5.** *Arhitektura HybridSN mreže*

Korištenje samo jednog od ovih pristupa ima svoje nedostatke, poput ne uzimanja u obzir veza između kanala, odnosno spektralnih informacija kod 2D-CNN ili pojavljivanje vrlo


kompleksnih modela kod 3D-CNN. Posebno su zanimljivi hibridni pristupi poput HybridSN modela, koji kombinira prednosti 3D konvolucija za spektralnu analizu s 2D konvolucijom za prostornu obradu [6]. Za 2D konvoluciju koristi se klasični pristup primjene kernela na ulaz u sloj, dok za 3D konvoluciju se koristi 3D kernel koji obavlja konvoluciju s 3D ulaznim podacima na više različitih kanala u isto vrijeme zadržavajući spektralne informacije. Ovakav model se pokazao kao znatno bolji u vidu performansi ali i računalnih zahtjeva u odnosu na modele koji koriste samo 2D ili 3D konvoluciju.

### 2.3. XAI metode pri klasifikaciji HSI

Kako CNN-ovi, unatoč visokoj točnosti, često funkcioniraju kao "crne kutije", XAI metode pružaju ključne uvide u proces donošenja odluka. Kao što je prethodno rečeno, hiperspektralne slike sadrže stotine spektralnih kanala, što CNN-ovima omogućuje preciznu klasifikaciju, ali istovremeno otežava razumijevanje koje su specifične spektralne ili prostorne značajke najviše utjecale na odluku. Interpretabilnost je ključna kako bi se osigurala pouzdanost modela u kritičnim primjenama (poput medicine, nadgledanja okoliša, itd.), identificirali potencijalni šum ili artefakti u podacima i potvrdila znanstvena osnova za dobivene rezultate.

Za interpretaciju CNN-ova u HSI analizi najčešće se koriste metode poput Grad-CAM-a, sensitivity analysis i druge.

Grad-CAM (engl. *Gradient-weighted Class Activation Mapping*) vizualizira prostorne regije koje su najviše doprinijele klasifikaciji generirajući toplinske karte (engl. *heatmap*) na osnovu gradijenata ciljane klase i aktivacija u posljednjem konvolucijskom sloju [7].



**Slika 2.6.** Generirana Grad-CAM toplotna karta za klasu asfalt



Analiza osjetljivosti (engl. *sensitivity analysis*, *SA*) proučava kako izlazi danog modela ovise o danim podacima na ulazu modela. SA pruža globalni uvid u stabilnost i pouzdanost modela promjenom ulaznih parametara. Neke od potencijalnih primjena su utvrđivanje: optimalne struktura modela, smislenosti izlaza modela kada se u obzir uzme ulaz, da model ne pokazuje ovisnost o naizgled nebitnim dijelovima ulaza, uzima li model u obzir cijeli spektar vrijednosti na ulazu, i druge [8].

U ovom radu primjenjuje se analiza osjetljivosti modela na pojedinačne spektralne kanale metodom nuliranja kanala. Model daje predikciju vjerojatnosti za ciljanu klasu, nakon čega se vrši brisanje podataka za svaki spektralni kanal u ulaznim podacima i daje na ulaz modela. Evaluira se promjena u predviđenoj vjerojatnosti nakon uklanjanja kanala. Razlika između originalne vjerojatnosti i vjerojatnosti nakon uklanjanja predstavlja mjeru njegovog utjecaja na konačnu odluku modela.

Glavna prednost ovog pristupa je što direktno kvantificira doprinos pojedinih spektralnih kanala modelu, omogućavajući identifikaciju ključnih valnih duljina za klasifikacijski zadatak. Jedan od nedostataka ove metode je računska kompleksnost jer zahtijeva  $N+1$  predikcija modela za svaki ulazni podatak bez pojedinog kanala (gdje je  $N$  broj spektralnih kanala) i također ne uzima u obzir potencijalne interakcije između različitih kanala.

### 3. EKSPERIMENTALNA ANALIZA

S ciljem određivanja utjecaja spektralnih kanala na krajnju klasifikaciju modela provedena je eksperimentalna analiza. S ukupnim brojem od 4 844 793 parametara korišten je HybridSN model [6] za klasifikaciju HSI slike podijeljene u manje dijelove koji sačinjavaju čitav dataset za treniranje i testiranje modela. Za treniranje modela korištena je Adam optimizacijska metoda s početnom stopom učenja od 0.001, a za funkciju gubitka korišten je *categorical cross-entropy*. Model je treniran s veličinom batcha od 256 i 100 za broj epoha.

Pavia University (PU) je korišteni dataset snimljen putem ROSIS senzora koji ima mogućnost bilježenja 115 spektralnih kanala u rasponu od 430-860nm [9]. Nakon inicijalne predobrade krajnji dataset je sačinjen od 103 kanala. Groundtruth dataseta se sastoji od 9 različitih klasa kao što je vidljivo na slici 3.1.



Slika 3.1. *Groundtruth Pavia University dataset-a*

Prije korištenja kao ulaz za model originalna HSI se prvo transformira PCA metodom kako bi se smanjila dimenzionalnost sa 103 na 15 dimenzija, nakon čega se dijeli na manje dijelove veličine 25x25 koji predstavljaju ulaz u model.

Kako bi se utvrdilo koji spektralni kanali najviše utječu na odluke modela, provedena je analiza osjetljivosti kroz perturbaciju kanala. Postupak se sastoji od inicijalne predikcije, za svaki ulazni patch izračunata je osnovna vjerojatnost pripadnosti ciljnoj klasi koristeći originalne podatke. Svaki spektralni kanal posebno je postavljen na nulu, a zatim je ponovo izvršena PCA transformacija s prethodno generiranim PCA komponentama i predikcija modela. Razlika između originalne vjerojatnosti i vjerojatnosti nakon uklanjanja kanala koristi se kao mjera njegovog doprinosa klasifikaciji, što je ta razlika veća to je veći utjecaj uklonjenog kanala na klasifikaciju.

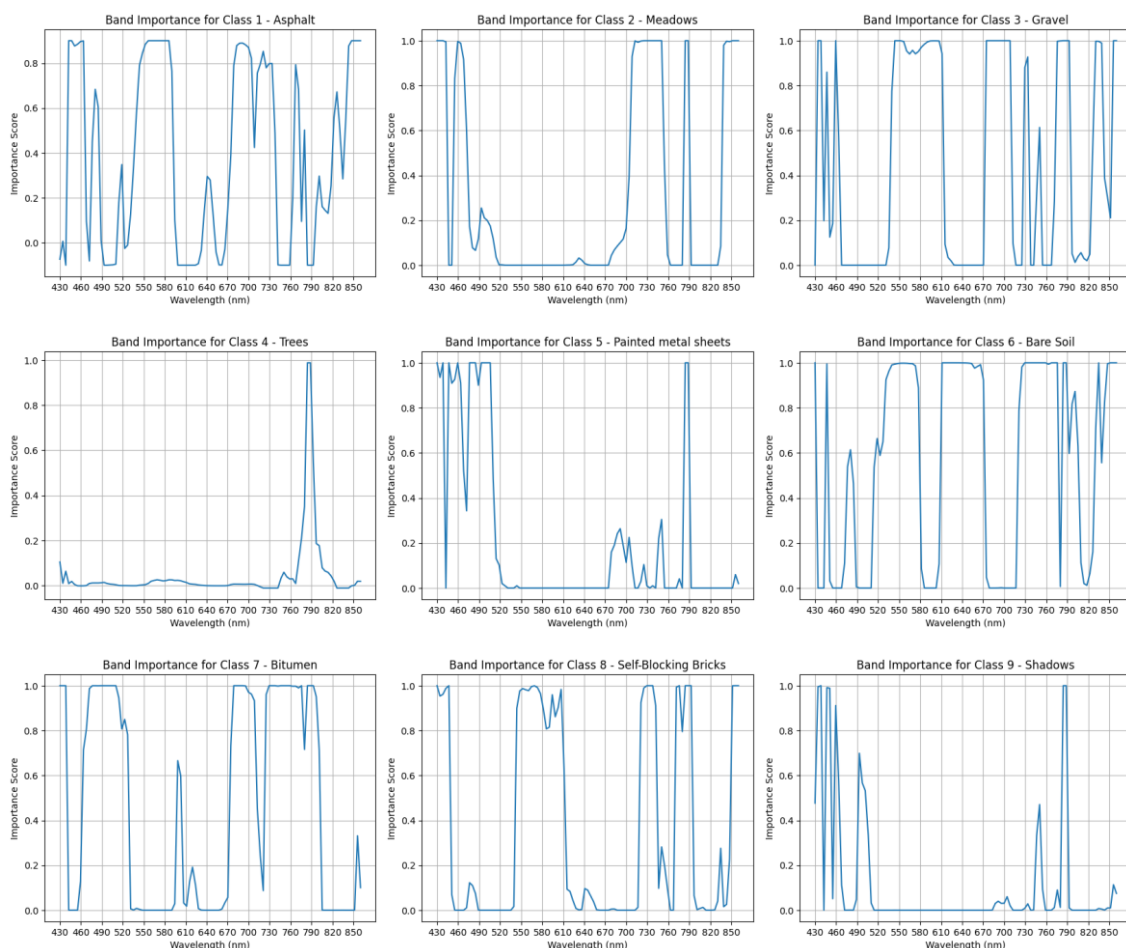
### 3.1. REZULTATI

Rezultati su prikazani u obliku spektralnog profila važnosti kanala, gdje je moguće očitati važnost generalnog utjecaja kanala na klasifikaciju kao i utjecaj kanala na pogrešnu klasifikaciju.

Pri SA računat je pokazatelj značajnosti (engl. *importance score*) na osnovu toga koliko je određen kanal bitan za točnu klasifikaciju, a ne njegov generalni utjecaj. Primjerice za neke kanale u nekim slučajevima dobiveni rezultat je negativan što znači da uklanjanje tog kanala model rezultira boljom klasifikacijom. Dobiveni rezultati za pojedinu klasu vidljivi su na slici 3.2. Za x osu je korišten raspon 430-860nm (spektralni raspon koji pokriva ROSIS senzor) dok je na y osi vidljiv pokazatelj značajnosti, gdje veće vrijednosti označavaju veći značaj spektra.

Moguće je primijetiti kako za prvu klasu, asfalt, najznačajniji kanali (s vrijednostima iznad 0.8) su u rasponima 440-460nm, 550-580nm, 680-700nm i 840nm pa nadalje. Crvena boja koja se nalazi u rasponu 620-750nm tipično se koristi za identificiranje umjetnih objekata poput cesta i građevina, te je i ovdje vidljiva izraženost tih spektara. Ključna je u tome što vegetacija upija ove spektre dok ga asfalt odbija, što pomaže u njihovom razlikovanju i identifikaciji [10]. Sličan slučaj moguće da se pojavljuje i sa zelenim spektrom vrijednosti (530-590nm) i bliskim infracrvenim (engl. *near infrared*, *NIR*) vrijednostima (760-900nm) koje biljke najviše odbijaju, što je i ovdje vidljivo kroz raspone 550-580nm i 840nm [10].

Prisutnost valnih duljina 440-460nm u plavom području nije očekivana, moguća objašnjenja su mokar ili vlažan asfalt čime dolazi do povećanja refleksije u ovom području, veći kontrast radi niže refleksije u odnosu na okolni prostor, utjecaj atmosferske magle koja ima najveći utjecaj na ove valne dužine ili pak pojave šumova u prikupljanju podataka.



**Slika 3.2.** Grafovi važnosti pojedinih spektara za 9 klasa PU dataset-a

Za klasu 2, travnjake, ponovno je vidljiv utjecaj spektara koje vegetacija najviše reflektira i upija. 700-750nm predstavlja crveni rub kojeg radi klorofila biljke značajno upijaju, dok 780-790nm raspon (NIR područje) značajno reflektiraju. Kao i kod asfalta valne dužine 430-460nm koje su unutar plavog područja imaju velik utjecaj, te su i moguća objašnjenja slična – prisutnost vodenih površina, atmosferske smetnje ili pojava šumova. Prisutne su i krajnje vrijednosti NIR spektra, 840-850nm. Klorofil ih reflektira dok je biljka zdrava ali kako se njen životni vijek približava kraju reflektiranje NIR valnih duljina se smanjuje.

Kod klase 3 (šljunak) najznačajnijim valnim duljinama pokazale su se: 440nm, 460nm, 540-560nm, 590-600nm, 670-700nm, 770-790nm, 830nm i 850nm. S obzirom na ovako širok niz vrijednosti unutar cijelog spektra moguće je slutiti na prisutnost raznih materija

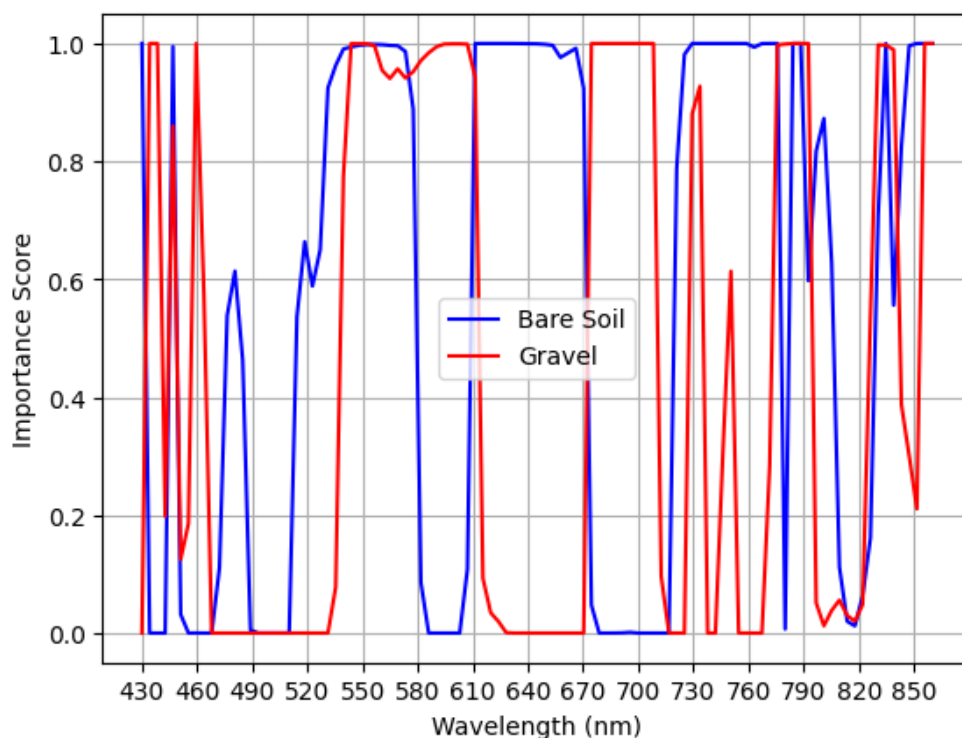
unutar šljunka radi kojih dolazi do ovakvog niza spektralnih vrijednosti. Moguća je prisutnost vode u vidu vlage (440, 460nm), organske materije koja sadrži klorofil (540-560nm – zeleno područje, 670-700nm – crveno područje, 770-790nm i 830-850nm – NIR područje). Šljunak, slično kao i arheološka nalazišta, omogućava bolje zadržavanje vlažnosti što stvara povoljne uvjete za biljni rast tijekom cijele godine i sušnih razdoblja. Posljedično dolazi do interakcije klorofila s elektromagnetnim spektrom [11]. Crveno i NIR područje može biti također značajno radi kontrasta s biljnom okolinom.

Drveće, odnosno klasa 4, ponovno pokazuje jednak uzorak kada je riječ o prisutnosti biljaka, gdje valne dužine u području oko 780nm (NIR područje) imaju najveći utjecaj.

Najveću ulogu u klasifikaciji obojenih metalnih limova (klasa 5) su imale valne dužine u plavom području (450-510nm) što ima smisla s obzirom na to da su limovi obojeni bojom plave nijanse. Tu se pojavljuje i raspon vrijednosti 780-790nm unutar NIR spektra. Pigmenti koji reflektiraju NIR područje sadržani u određenim premazima nisu rijetki radi njihovog utjecaja na smanjenje unutrašnjih temperatura [12], samim tim na potrošnju energije, te je njihovo područje upotrebe široko. Može se pretpostaviti da u našem slučaju upravo oni su odgovorni za pojavu navedenih valnih duljina kao značajnih unutar NIR spektra.

Golo tlo (klasa 6) bilježi valne dužine od 430nm, 440nm, 540-560nm, 610-660nm, 730-770nm, 780nm, 830nm i 850nm kao one koje su imale najveći značaj. Kao što je vidljivo na slici 3.3 rezultati značajnosti su slični onima 3. klase, šljunak. Jednako tako možemo pretpostaviti jednake uzroke za ovakav rezultat - mješavina vode, minerala i organske materije koje sadrže klorofil. Reflektivnost golog tla najviše ovisi o njegovoj kompoziciji, ona koja su bogata željeznim oksidom rezultiraju većom refleksijom crvenog i NIR spektra koja se u našem slučaju očituje u rasponu vrijednosti 610-660nm i 730-770nm, 780nm, 830nm i 850nm [10], [12].

Ovdje je vidljiva i kvaliteta modela kada gledamo visoku razinu točnosti klasifikacije koju dostiže za ove dvije klase s obzirom na sličnost njihovih spektralnih potpisa.










**Slika 3.3** Graf rezultata značajnosti golog tla i šljunka

Bitumen (klasa 7) je tamni, viskozni materijal dobiven preradom nafte, korišten u izgradnji cesta i hidroizolacijama. Značajne valne dužine koje su prisutne su 430nm, 470-510nm, 680-700nm, 730-790nm. Ponovno se može pretpostaviti prisutnost vode u nekom obliku ili aditiva koji nalikuju vodi (430nm, 470-510nm), te algi ili lišajeva koje sadrže klorofil što nije vrlo vjerojatno. Bolje objašnjenje može biti kemijska struktura bitumena i termodinamička svojstva koja posjeduje [13].

Najviše zaslužne za točnu klasifikaciju samoblokirajućih blokova (klasa 8) su valne dužine 430nm, 440nm, 550nm, 570nm, 730nm, 770nm, 790nm i 850nm. Značaj navedenih spektralnih vrijednosti može se objasniti teksturom, bojom i sastavom materijala kao i njegovim termodinamičkim svojstvima. U slučaju da materijal upija vodu vrijednosti 430nm, 440nm, 550nm su rezultat toga.

Sjene (klasa 9) imaju valne dužine 430nm, 440nm i 790nm kao najznačajnije. Plavo područje je najosjetljivije [10], što ga čini najizraženijim kada je riječ o sjenama. U NIR-u imaju izrazito nisku refleksiju jer ne primaju direktno sunčevo zračenje na koje okolna vegetacija i određeni materijalni imaju utjecaj. Također sjene imaju manju toplotnu emisiju u odnosu na nezasjenjena područja što može uzrokovati manje emitiranje IR zračenja.





**Slika 3.4.** *Grafovi važnosti pojedinih spektara u pogrešnoj klasifikaciji za 9 klasa PU dataset-a*

Na slici 3.4 može se vidjeti utjecaj pojedinih valnih duljina na netočnu klasifikaciju, veće negativne vrijednosti predstavljaju veći utjecaj na pogrešnu klasifikaciju.

750nm, 790nm su valne dužine klase 1 (asfalt) koje imaju najveći utjecaj na netočnu klasifikaciju. Visoka refleksija u NIR području može dovesti do miješanja s vegetacijom ili vlažnim površinama, također zagrijavanje do kojeg često dolazi kod asfaltnih površina može igrati ulogu u zbunjivanju modela.

Kod klase 2, travnjaci, valne dužine u NIR području poput one koja se javlja u ovom slučaju od 800nm je karakteristična za veliki broj ostale vegetacije kako odumire i klorofil prestaje da reflektira NIR spektre.

Za klase šljunak (klasa 3), golo tlo (klasa 6) i samoblokirajući blokovi (klasa 8) prisutne su slične valne dužine koje su se pokazale problematičnima. To su 640-650nm (crvena), 720nm, 760nm (NIR) za šljunak, 440nm, 470nm (plava), 670-710nm (crvena), 810nm (NIR) za golo tlo i 490-540nm (zelena), 670nm (crvena), 700-710nm (crveni rub), 770nm, 780nm, 800nm (NIR) za samoblokirajuće blokove. Karakteristike valnih duljina koje su bile bitne pri točnoj klasifikaciji ovdje se pokazuju negativnim. Moguće je da prisutnost zelene materije koja reflektira NIR u šljunku buni model s golim tlom i samoblokirajućim blokovima koji sadrže materijale koji reflektiraju jednake spektre. Promatranjem matrice konfuzije moguće je vidjeti da model više puta odlučuje da je predviđena klasa samoblokirajući blokovi za stvarne klase šljunka i golog tla, što ujedno čini i dva najčešća slučaja netočne klasifikacije. Kod golog tla vlažnost tla potencijalno mijenja refleksijske karakteristike, ali i različiti sastavi tla mogu biti odgovorni za zbunjivanje modela. Kao i



za druge dvije klase, nedosljednost i varijacije u sastavu, boji i izgledu dovode do potencijalnih problema pri klasificiranju samoblokirajućih blokova.

Kod klase 4, drveće valne dužine 720-740nm se pokazuju najodgovornijima za netočnu klasifikaciju. Veliki broj ostale vegetacije ima sličan spektralni potpis, različite vrste drveća imaju različite spektralne karakteristike, sjene krošnji mogu izobličiti očitane signale su neki od razloga zašto model može napraviti krivu klasifikaciju.

Kao što je prethodno rečeno plava spektralna područja su najosjetljivija i podložna su izobličenjima, bilo to radi atmosferskih smetnji ili utjecaja manjih čestica. Ovo može biti objašnjenje za valnu dužinu 460nm prisutnu kod klase 9, sjene. Druga valna duljina od 710nm koja pravi probleme u klasifikaciji može biti izazvana radi različitih intenziteta svjetlosti ili temperature kod različitih sjena.

Za klasu 7 (bitumen) i 5 (obojeni metalni limovi) nije došlo do niti jedne netočne klasifikacije stoga niti njihovi pripadajući grafovi nisu prisutni.

## 4. ZAKLJUČAK

Hiperspektralne slike sve se više koriste u različitim područjima zbog svoje sposobnosti detekcije materijala na temelju njihovih jedinstvenih spektralnih potpisa. Za pouzdanu primjenu HSI točna klasifikacija materijala i objekata je ključna. Kako bi se iskoristio puni potencijal HSI podataka, neophodni su kvalitetni modeli i metode analize.

Rezultati analize spektralnih karakteristika pojedinih klasa direktno ovise o kvaliteti ground truth podataka koji su korišteni za treniranje modela, kao i o mogućim atmosferskim smetnjama prisutnim prilikom snimanja. Stoga se javlja potreba za standardizacijom atmosferskih uvjeta u kojima se HSI snimaju kako bi se omogućila konzistentna analiza istih. Analiza odluka koje model pravi je ključna kako bi se ostvarilo povjerenje u model i provjeru dosljednosti s poznatim fizikalnim principima.

Iako ovaj rad nastoji ostvariti korak u tom smjeru, potrebno je naglasiti da interakcije između pojedinih spektralnih kanala, koje mogu značajno utjecati na konačnu klasifikaciju, nisu eksplicitno uzete u obzir u ovoj analizi, što predstavlja važno ograničenje koje bi se trebalo razmotriti u budućim istraživanjima.

Za daljnje unaprjeđenje analize neophodno je provesti detaljnu validaciju terenskim podacima, jer kao što je prikazano analizom, spektralni kanali koji su identificirani kao bitni u postupku klasifikacije mogu biti izazvani nizom fizičkih materija.

## LITERATURA

- [1] GISGeography, „Multispectral vs Hyperspectral Imagery Explained“ [online], 23-srp-2014. .
- [2] J., Qin, K., Chao, M. S., Kim, R., Lu, T. F., Burks, „Hyperspectral and multispectral imaging for evaluating food safety and quality“, *Journal of Food Engineering*, izd. 2, sv. 118, str. 157–171, ruj. 2013.
- [3] *Hyperspectral remote sensing of vegetation*, Second edition. CRC Press: Boca Raton, 2019.
- [4] „Spectral Characteristics Viewer | Landsat Missions“ [online]. Dostupno na: <https://landsat.usgs.gov/spectral-characteristics-viewer>. [Pristupljeno: 15.5.2025.].
- [5] X., Yang, Y., Ye, X., Li, R. Y. K., Lau, X., Zhang, X., Huang, „Hyperspectral Image Classification With Deep Learning Models“, *IEEE Transactions on Geoscience and Remote Sensing*, izd. 9, sv. 56, str. 5408–5423, ruj. 2018.
- [6] S. K., Roy, G., Krishna, S. R., Dubey, B. B., Chaudhuri, „HybridSN: Exploring 3-D–2-D CNN Feature Hierarchy for Hyperspectral Image Classification“, *IEEE Geoscience and Remote Sensing Letters*, izd. 2, sv. 17, str. 277–281, velj. 2020.
- [7] R. R., Selvaraju, A., Das, R., Vedantam, M., Cogswell, D., Parikh, D., Batra, „Grad-CAM: Why did you say that?“ arXiv, 25-sij-2017.
- [8] A., Saltelli, K., Chan, E. M., Scott, *Sensitivity Analysis: Gauging the Worth of Scientific Models*. John Wiley & Sons, 2000.
- [9] „Hyperspectral Remote Sensing Scenes - Grupo de Inteligencia Computacional (GIC)“ [online]. Dostupno na: [https://www.ehu.eus/ccwintco/index.php/Hyperspectral\\_Remote\\_Sensing\\_Scenes#Pavia\\_University\\_scene](https://www.ehu.eus/ccwintco/index.php/Hyperspectral_Remote_Sensing_Scenes#Pavia_University_scene). [Pristupljeno: 18.5.2025.].
- [10] GISGeography, „Spectral Signature Cheatsheet in Remote Sensing“ [online], 27-ožu-2014. .
- [11] G. J., Verhoeven, „Near-Infrared Aerial Crop Mark Archaeology: From Its Historical Use to Current Digital Implementations“.
- [12] P., Jeevanandam, R. S., Mulukutla, M., Phillips, S., Chaudhuri, L. E., Erickson, K. J., Klabunde, „Near Infrared Reflectance Properties of Metal Oxide Nanoparticles“, *J. Phys. Chem. C*, izd. 5, sv. 111, str. 1912–1918, velj. 2007.
- [13] E. A., Cloutis, „Spectral Reflectance Properties of Hydrocarbons: Remote-Sensing Implications“, *Science*, izd. 4914, sv. 245, str. 165–168, srp. 1989.